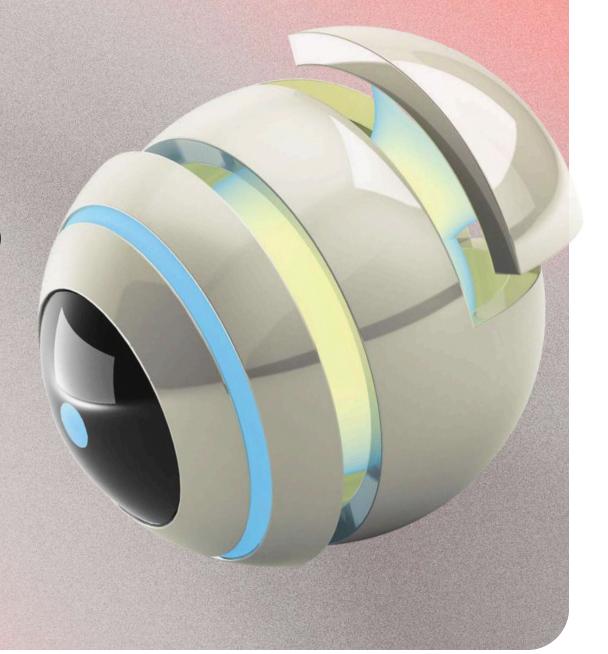
Climate and Floods in Jakarta



C Dataset Link:

Climates and Floods in Jakarta, 2016 - 2020.

Check it! →

Our Members

Benediktus Arthur S.

27022555911

Hendy Cahyadi T.

2702290135

Stefanus Marcellino

2702215284

Joseph B.

2702261712

Jordi A. Iskandar

2702324631

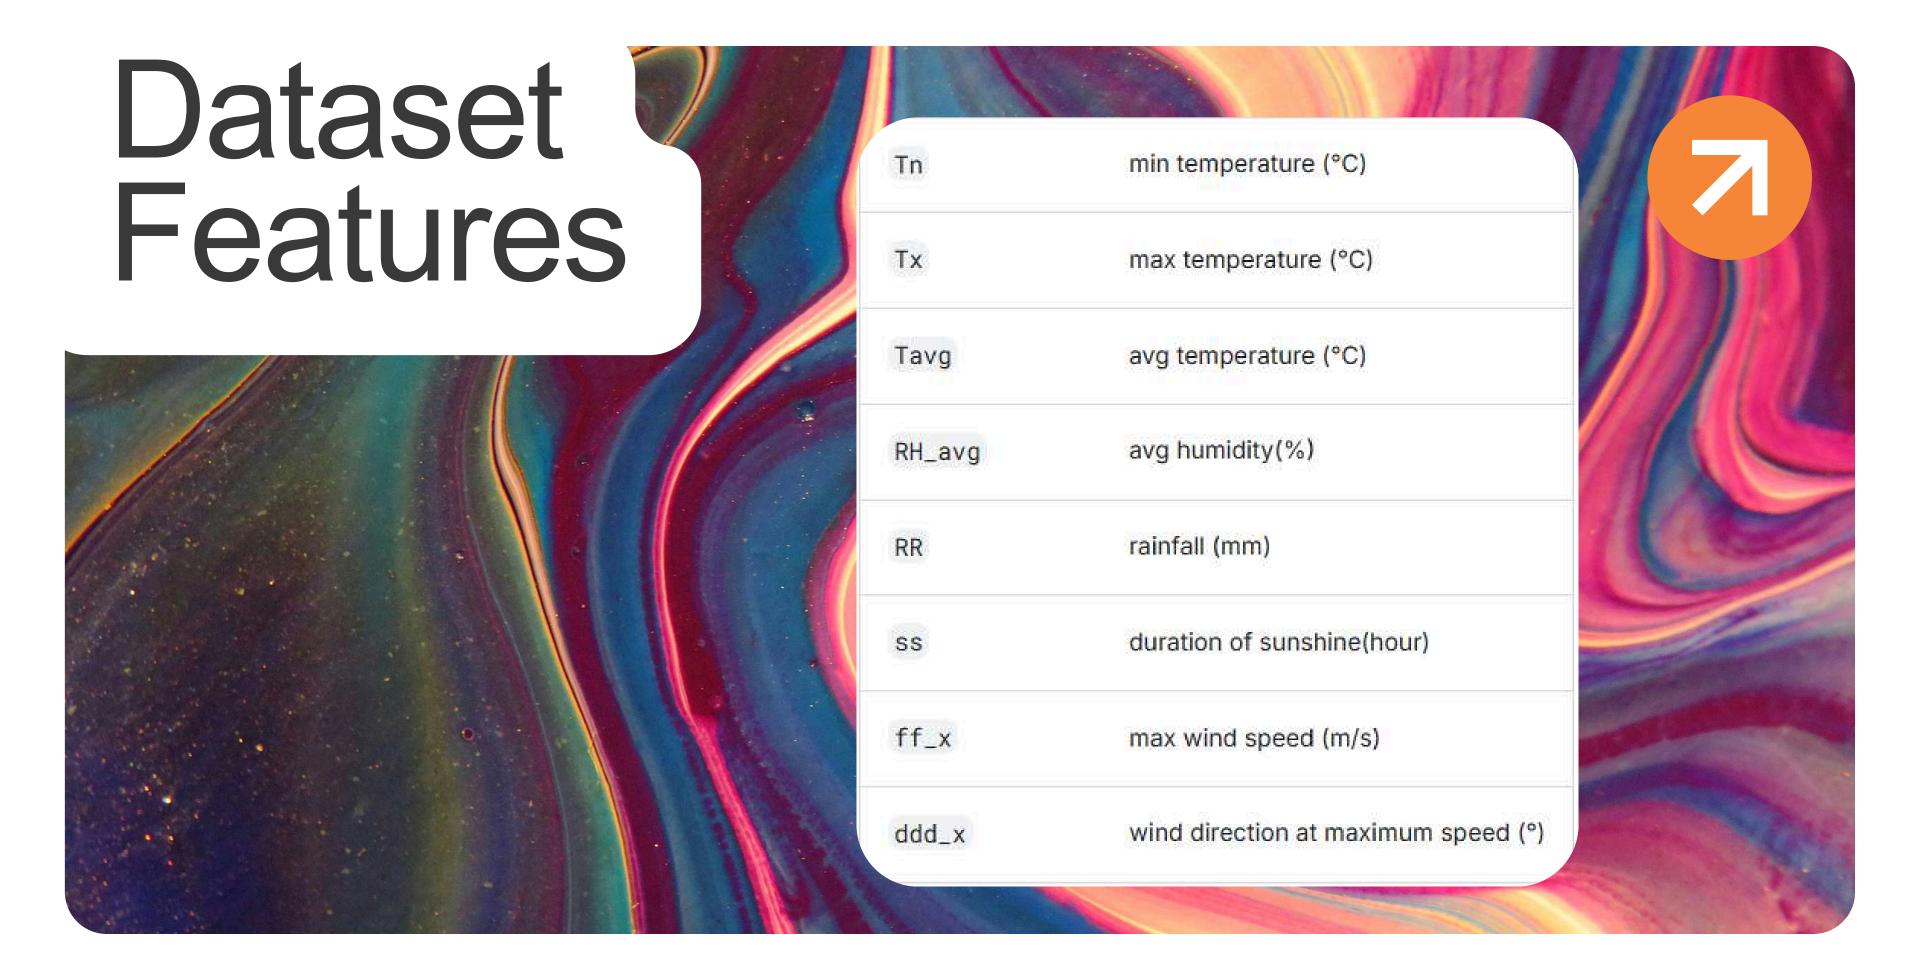
Geoffrey D. Julianto

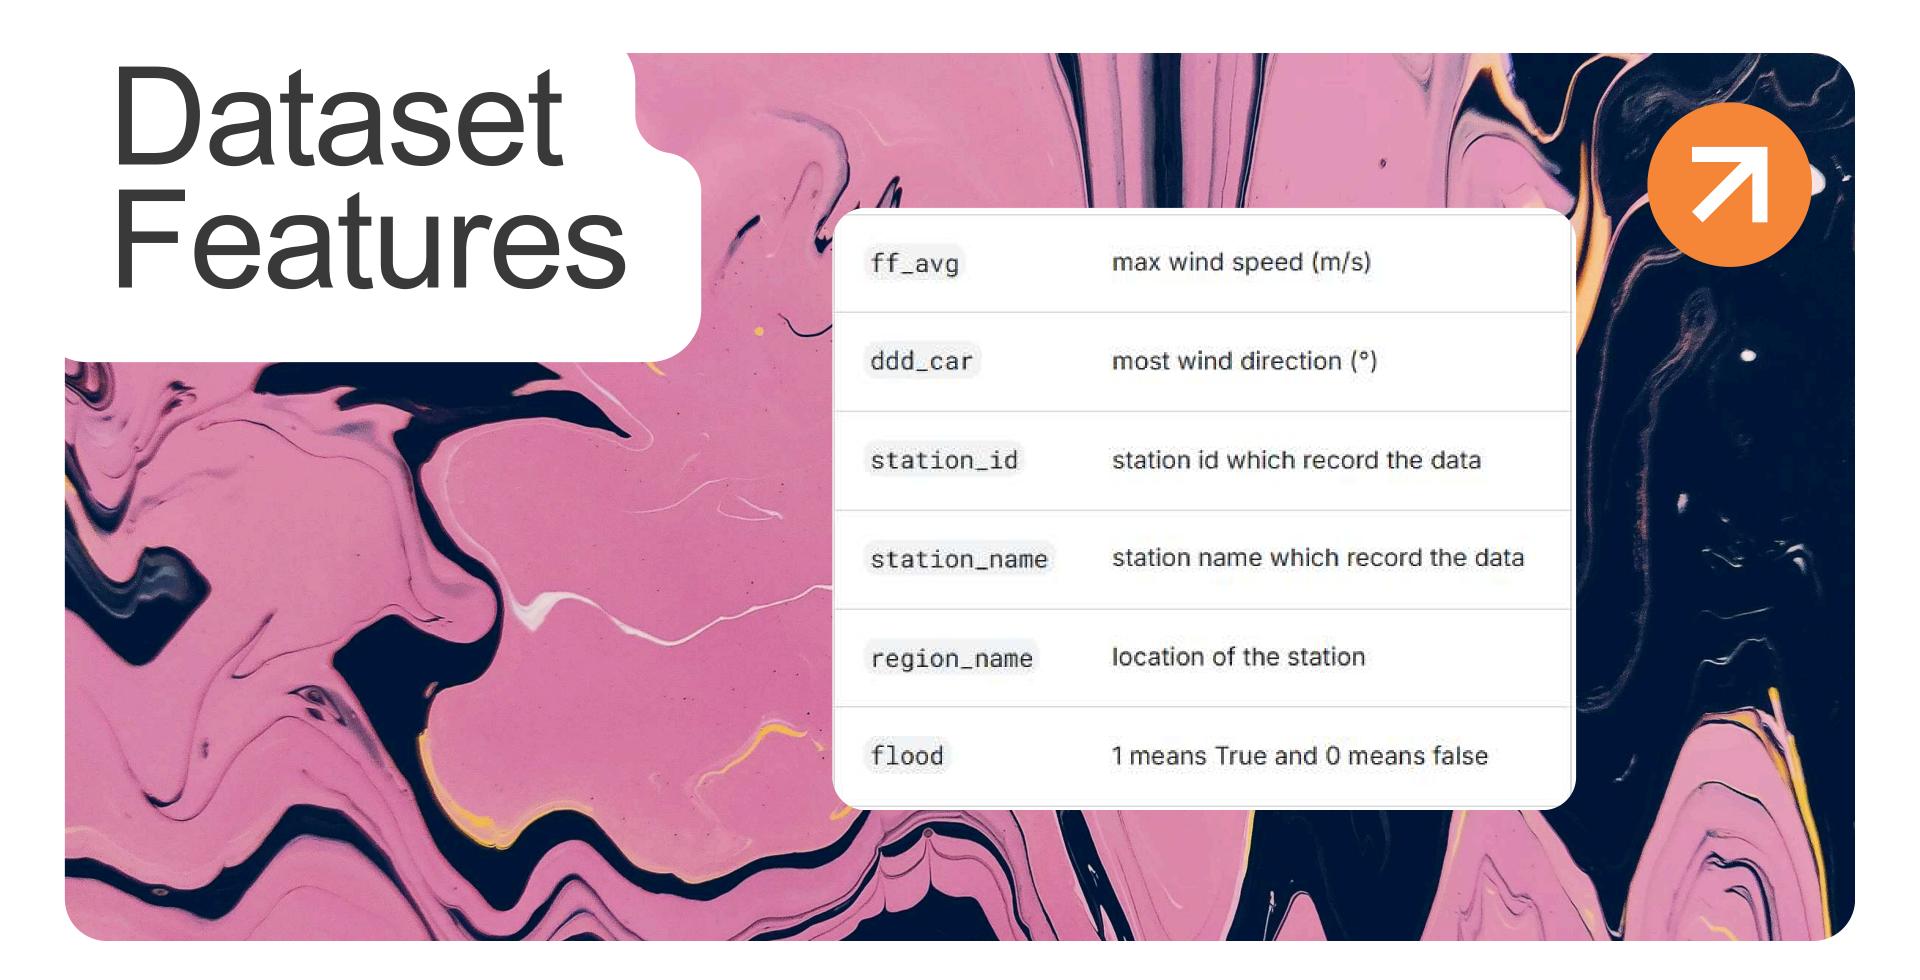
2702255773

Latar Belakang

Background Study

Jakarta merupakan salah satu kota di Indonesia yang sering mengalami bencana banjir, terutama saat musim hujan. Banjir menyebabkan kerugian besar, baik dari segi ekonomi, infrastruktur, keselamatan masyarakat. Tingginya maupun intensitas hujan, buruknya sistem drainase, serta urbanisasi yang cepat membuat banjir menjadi masalah yang kompleks dan berulang setiap tahun. Oleh karena itu, diperlukan sistem prediksi banjir yang dapat membantu pemerintah dan masyarakat dalam mengambil tindakan preventif secara lebih cepat dan tepat. Dalam proyek ini, kami membangun model prediksi banjir menggunakan data cuaca dan data stasiun pemantau untuk memperkirakan kemungkinan terjadinya banjir di wilayah Jakarta.









Pre-Processing

Dataset yang didapat dari kaggle akan ditelusuri untuk menghapus data kosong, dan juga mengurangi outlier melalui metode IQR.

Methodo Ioav

Exploratory Analysis

Dataset yang sudah bersih kemudian akan di-explore untuk mendapatkan knowledge baru yang berguna.

Methodology Cont.



Logistic Regression

Setelah itu, dataset bersih akan digunakan untuk training model prediktif. Data akan ditambahkan melalui SMOTE untuk mengatasi imbalance.

Random Forest

Selain Logistic Regression, algoritma Random Forest juga akan diterapkan untuk membandingkan akurasi model.

```
. .
import pandas as pd
import numpy as np
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.pipeline import Pipeline
from sklearn.compose import ColumnTransformer
from sklearn.impute import SimpleImputer # Still needed for
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')
def load_and_examine_data(file_path):
   df = pd.read_csv(file_path)
   print("Dataset shape:", df.shape)
   print("\nFirst 5 rows:")
   print(df.head())
   print("\nData types:")
   print(df.dtypes)
   print("\nMissing values per column:")
   print(df.isnull().sum()[df.isnull().sum() > 0])
   print("\nFlood event distribution:")
   print(df['flood'].value_counts(normalize=True) * 100)
def remove_missing_rows(df):
    print("\nRemoving rows with missing values...")
    before = df.shape[0]
   df = df.dropna()
   after = df.shape[0]
    print(f"Removed {before - after} rows. New shape: {df.shape}")
    return df
def detect_and_handle_outliers(df, columns_to_check=None):
    if columns to check is None:
        columns_to_check = [col for col in ['Tn', 'Tx', 'Tavg',
'RH_avg', 'RR', 'ss', 'ff_x', 'ff_avg']
                           if col in df.columns and
pd.api.types.is_numeric_dtype(df[col])]
   print("\nOutlier detection and handling:")
    for col in columns_to_check:
       Q1 = df[col].quantile(0.25)
        Q3 = df[col].quantile(0.75)
        IQR = Q3 - Q1
        lower_bound = Q1 - 1.5 * IQR
        upper_bound = Q3 + 1.5 * IQR
        outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
        print(f"{col}: {len(outliers)} outliers capped")
        df[col] = np.where(df[col] < lower_bound, lower_bound, df[col])</pre>
        df[col] = np.where(df[col] > upper_bound, upper_bound, df[col])
    return df
```

```
. .
def prepare_features_and_target(df):
   numerical_features = [col for col in ['Tn', 'Tx', 'Tavg', 'RH_avg',
'RR', 'ss', 'ff_x', 'ff_avg']
                         if col in df.columns and
pd.api.types.is_numeric_dtype(df[col])]
   potential_categorical = ['station_id', 'station_name',
'region_name', 'ddd_x', 'ddd_car']
   categorical_features = [col for col in potential_categorical if col
in df.columns]
    target = 'flood'
   X = df[numerical_features + categorical_features]
   y = df[target]
    numeric_transformer = Pipeline(steps=[
       ('scaler', StandardScaler())
   if categorical_features:
       categorical_transformer = Pipeline(steps=[
           ('encoder', OneHotEncoder(handle_unknown='ignore',
sparse_output=False))
       1)
       preprocessor = ColumnTransformer(transformers=[
           ('num', numeric_transformer, numerical_features),
            ('cat', categorical_transformer, categorical_features)
       1)
   else:
        preprocessor = ColumnTransformer(transformers=[
           ('num', numeric_transformer, numerical_features)
   X_processed = preprocessor.fit_transform(X)
    if categorical_features:
           categorical_feature_names = preprocessor.transformers_[1]
[1].named_steps['encoder'].get_feature_names_out(categorical_features).t
           feature_names = numerical_features +
categorical_feature_names
       except:
           feature_names = numerical_features + [f'cat_{i}' for i in
range(X_processed.shape[1] - len(numerical_features))]
        feature names = numerical features
   print(f"\nFinal preprocessed shape: {X_processed.shape}")
    print(f"Number of features: {len(feature_names)}")
    return X_processed, y, preprocessor, feature_names
```



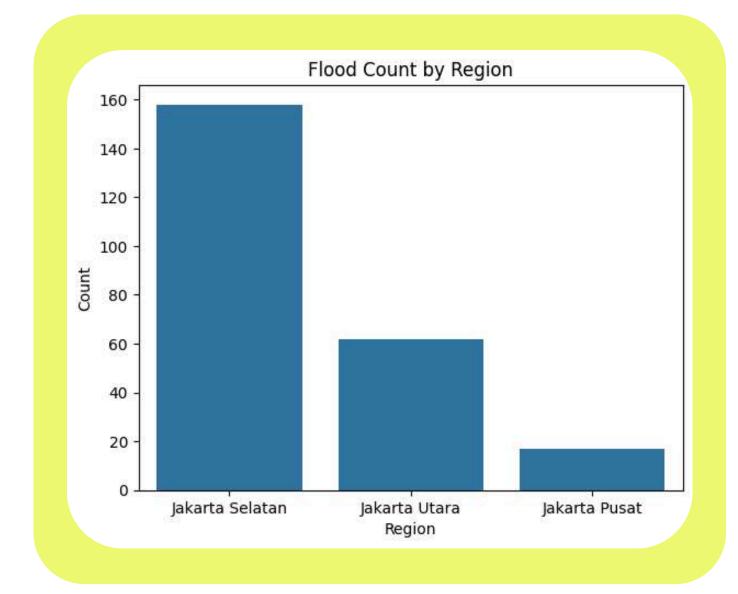
Data Pre-Processing

Null dan duplicate di hapus, outlier di cap.

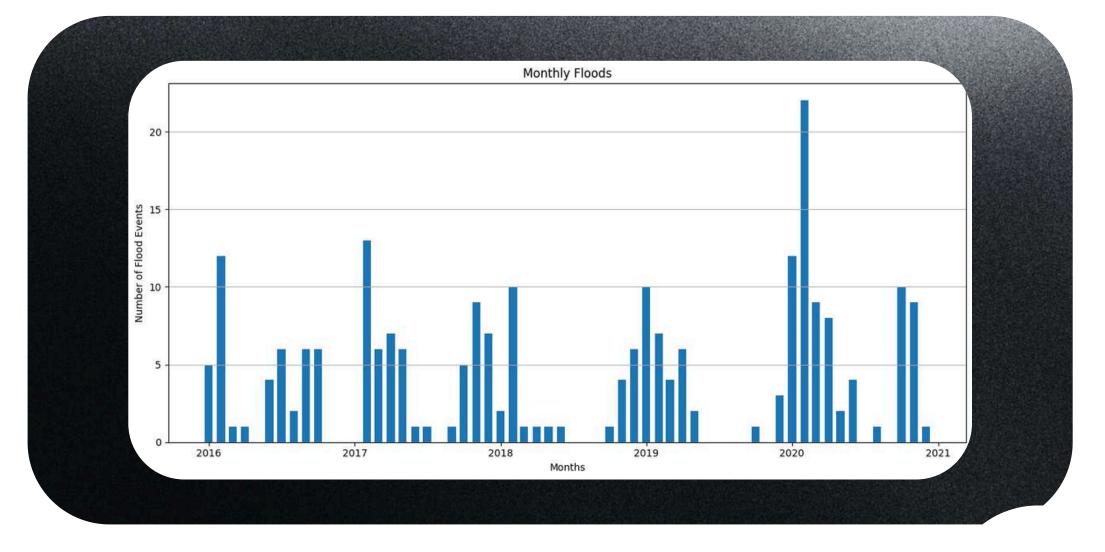
```
sns.countplot(x='region_name', data=df_processed[df_processed['flood']
== 1])
plt.title("Flood Count by Region")
plt.xlabel("Region")
plt.ylabel("Count")
plt.xticks(rotation=0)
plt.show()
```

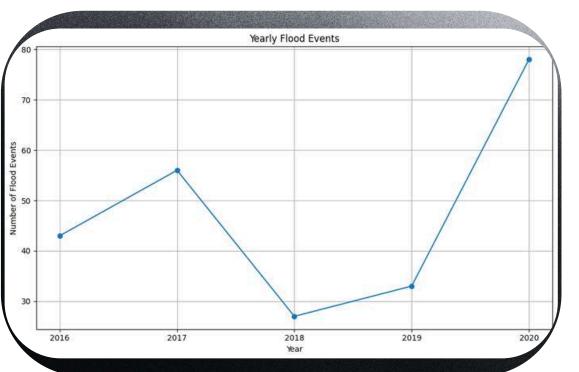
Exploratory Analysis 1

Visualisasi mengenai jumlah kebanjiran jika dipisahkan sesuai dengan daerah terjadinya.



```
df_processed['date'] = pd.to_datetime(df_processed['date'])
flood_df = df_processed[df_processed['flood'] == 1]
monthly_floods =
flood_df.groupby(flood_df['date'].dt.to_period('M')).size()
monthly_floods.index = monthly_floods.index.to_timestamp() # Convert
import matplotlib.pyplot as plt
plt.figure(figsize=(12, 6))
plt.bar(monthly_floods.index, monthly_floods.values, width=20) # width
plt.title('Monthly Floods')
plt.xlabel('Months')
plt.ylabel('Number of Flood Events')
plt.grid(axis='y')
plt.tight_layout()
plt.show()
yearly_floods = flood_df.groupby(flood_df['date'].dt.year).size()
plt.figure(figsize=(10, 6))
plt.plot(yearly_floods.index.values, yearly_floods.values, marker='o',
linestyle='-')
plt.title('Yearly Flood Events')
plt.xlabel('Year')
plt.ylabel('Number of Flood Events')
plt.xticks(yearly_floods.index.values) # Make sure only year integers
plt.grid(True)
plt.tight_layout()
plt.show()
```





Exploratory 2

Peristiwa banjir bulanan dan tahunan.

Why Logistic Regression?

Cocok untuk
prediksi biner,
klasifikasi banjir
adalah 1 (banjir),
dan 0 (tidak banjir).

Sederhana dan mudah dipahami.

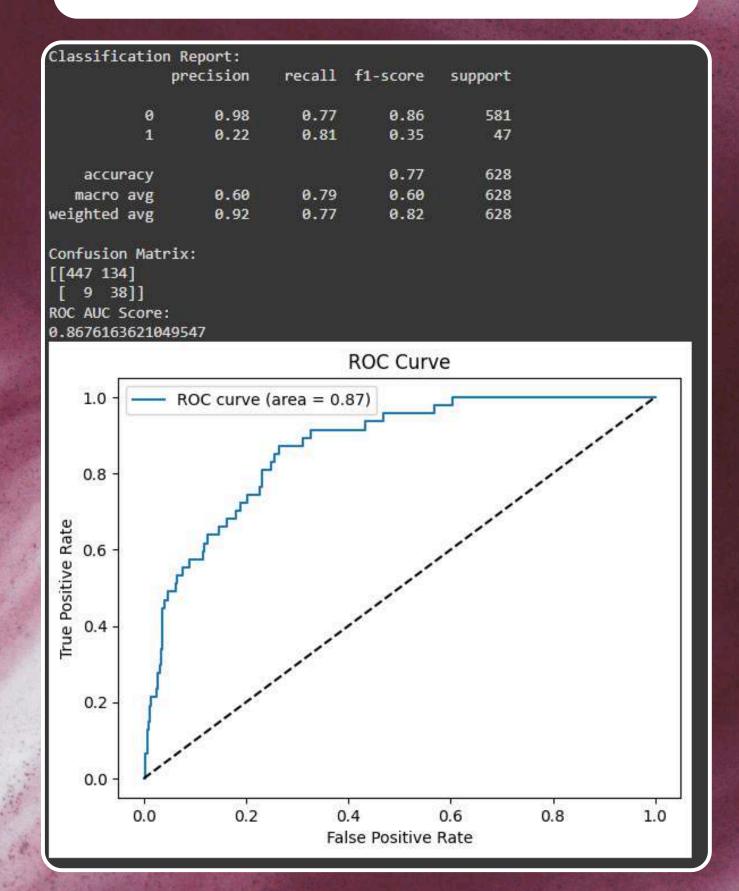
Cocok dengan teknik SMOTE.

Efisien dan cepat trainingnya.

Performa baik pada data yang terstruktur.

```
. .
from sklearn.model_selection import train_test_split
from imblearn.over_sampling import SMOTE
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, confusion_matrix, roc_auc_score
X = df_processed.drop(columns=['flood', 'ddd_car', 'station_name', 'station_id', 'date', 'region_name'])
y = df_processed['flood']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)
smote = SMOTE(random_state=42)
X_train_smote, y_train_smote = smote.fit_resample(X_train, y_train)
model = LogisticRegression(max_iter=1000, random_state=42)
model.fit(X_train_smote, y_train_smote)
y_pred = model.predict(X_test)
y_pred_proba = model.predict_proba(X_test)[:, 1]
roc_auc = roc_auc_score(y_test, y_pred_proba)
print("Classification Report:")
print(classification_report(y_test, y_pred))
print("Confusion Matrix:")
print(confusion_matrix(y_test, y_pred))
print("ROC AUC Score:")
print(roc_auc_score(y_test, model.predict_proba(X_test)[:, 1]))
import matplotlib.pyplot as plt
from sklearn.metrics import roc_curve
fpr, tpr, thresholds = roc_curve(y_test, y_pred_proba)
plt.plot(fpr, tpr, label=f'ROC curve (area = {roc_auc:.2f})')
plt.plot([0, 1], [0, 1], 'k--')
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC Curve')
plt.legend()
plt.show()
```

Logistic Regression



Hasil Logistic Regression

Classification Report:						
pr	ecision	recall	f1-score	support		
0	0.98	0.77	0.86	581		
1	0.22	0.81	0.35	47		
accuracy			0.77	628		
macro avg	0.60	0.79	0.60	628		
weighted avg	0.92	0.77	0.82	628		
Confusion Matrix:						
[[447 134]						
[9 38]]						
ROC AUC Score:						
0.86761636210495	47					

Accuracy: 0.77

Memprediksi dengan benar sekitar 77% total data.

Precision (0): 0.98 - 0.77

Hampir semua prediksi "tidak banjir" benar, dan dari semua kejadian "tidak banjir", 77% berhasil dikenali model.

Precision (1): 0.22 - 0.81

Dari semua yang diprediksi "banjir", hanya 22% yang banjir sebenarnya. Model berhasil mengenali 81% dari semua kejadian banjir, ini hasil yang baik.

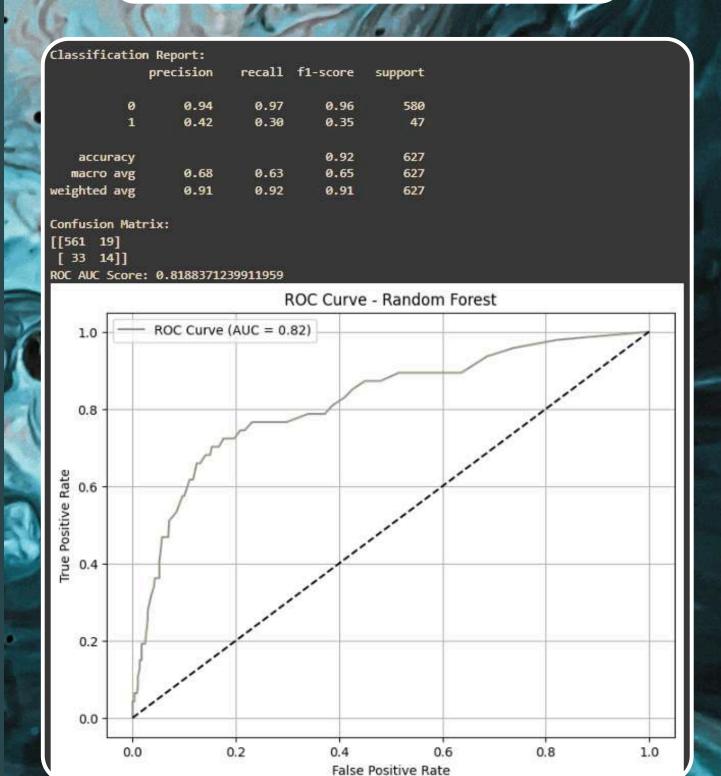
ROC AUC Score: 0.87

Model memiliki performa cukup baik dalam membedakan antara kelas banjir dan tidak banjir.

```
from sklearn.ensemble import RandomForestClassifier
X = df_processed.drop(columns=['flood', 'ddd_car', 'station_name', 'station_id', 'date', 'region_name']) # drop
y = df_processed['flood']
features = X.columns
X_train, X_test, y_train, y_test = train_test_split(X, y, stratify=y, test_size=0.2, random_state=42)
sm = SMOTE(random_state=42)
X_train_res, y_train_res = sm.fit_resample(X_train, y_train)
model = RandomForestClassifier(n_estimators=100, random_state=42)
model.fit(X_train_res, y_train_res)
y_pred = model.predict(X_test)
y_pred_proba = model.predict_proba(X_test)[:, 1]
print("\nClassification Report:")
print(classification_report(y_test, y_pred))
print("Confusion Matrix:")
print(confusion_matrix(y_test, y_pred))
print("ROC AUC Score:", roc_auc_score(y_test, y_pred_proba))
fpr, tpr, _ = roc_curve(y_test, y_pred_proba)
plt.figure(figsize=(8, 6))
plt.plot(fpr, tpr, label='ROC Curve (AUC = %.2f)' % roc_auc_score(y_test, y_pred_proba))
plt.plot([0, 1], [0, 1], 'k--')
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC Curve - Random Forest')
plt.legend()
plt.grid(True)
plt.show()
feat_importances = pd.Series(model.feature_importances_, index=features).sort_values(ascending=False)
plt.figure(figsize=(10, 6))
sns.barplot(x=feat_importances, y=feat_importances.index)
plt.title('Feature Importances - Random Forest')
plt.xlabel('Importance')
plt.ylabel('Feature')
plt.tight_layout()
plt.show()
```

.

Random Forest



Hasil Random Forest

Classification Report:						
	precision	recall	f1-score	support		
0	0.94	0.97	0.96	580		
1	0.42	0.30	0.35	47		
accuracy			0.92	627		
macro avg	0.68	0.63	0.65	627		
weighted avg	0.91	0.92	0.91	627		
Confusion Matrix:						
[[561 19] [33 14]]						

Accuracy: 0.92

Memprediksi dengan benar sekitar 92% total data.

Precision (0): 0.94 - 0.97

Hampir semua prediksi "tidak banjir" benar. Dari semua kejadian "tidak banjir", 94% berhasil dikenali oleh model, dan model mengenali 97% dari semua data yang benar-benar tidak banjir.

Precision (1): 0.42 - 0.30

Dari semua yang diprediksi sebagai "banjir", hanya 42% yang benarbenar banjir. Model berhasil mengenali 30% dari semua kejadian banjir yang sebenarnya, menunjukkan adanya kekurangan dalam mendeteksi kasus banjir.

ROC AUC Score: 0.82

Model memiliki kemampuan cukup baik dalam membedakan antara kelas banjir dan tidak banjir, meskipun lebih rendah dibandingkan Logistic Regression.

Conclusion

Jakarta semakin rentan terhadap banjir akibat perubahan iklim dan infrastruktur yang kurang memadai, sehingga diperlukan model prediktif yang akurat. Dalam penelitian ini, dua algoritma yang diuji adalah Logistic Regression dan Random Forest. Logistic Regression menunjukkan nilai ROC AUC sebesar 87% dan recall 81%, menjadikannya cocok untuk mendeteksi sebanyak mungkin kejadian banjir, meskipun menghasilkan banyak false positives. Di sisi lain, Random Forest memiliki akurasi keseluruhan 92% dan precision 42%, namun recall-nya hanya 30%, sehingga lebih cocok jika prioritasnya adalah mengurangi alarm palsu dan dapat mentoleransi terlewatnya beberapa kejadian banjir. Maka, pemilihan model tergantung pada prioritas: deteksi maksimal atau prediksi yang lebih spesifik.

